

BÀI THI CUỐI KỲ

Phần 1: Trắc Nghiệm & Trả Lời Câu Hỏi Ngắn

Câu 1

1. Chọn đáp án A

Câu 2 – 4

2. Chọn đáp án D
3. Chọn các đáp án B, D, E
4. Ta có ma trận nhầm lẫn sau:

		Actual values	
		Positive (1)	Negative (0)
Predicted values	Positive (1)	TP (<i>dự đoán núi lửa phun trào và thực tế núi lửa phun trào</i>)	FP (<i>dự đoán núi lửa phun trào nhưng thực tế núi lửa không phun trào</i>)
	Negative (0)	FN (<i>dự đoán núi lửa không phun trào nhưng thực núi lửa phun trào</i>)	TN (<i>dự đoán núi lửa không phun trào và thực tế núi lửa không phun trào</i>)

Trong trường hợp dự đoán phun trào núi lửa:

- Nếu ưu tiên an toàn: Nếu việc phát hiện phun trào là ưu tiên hàng đầu để bảo vệ tính mạng con người, có thể chọn ngưỡng thấp hơn để tối ưu hóa chỉ số recall, chấp nhận FP cao (có thể dẫn đến sơ tán không cần thiết).
- Nếu ưu tiên chi phí: Nếu chi phí sơ tán cao và ta muốn giảm thiểu sự hoang mang trong cộng đồng, có thể chọn ngưỡng cao hơn để tối ưu hóa chỉ số precision, chấp nhận FN cao (có thể dẫn đến rủi ro cao nếu không sơ tán).

Câu 5 – 6

Ta có ma trận nhầm lẫn sau :

		Predicted values	
		Positive (1)	Negative (0)
Actual values	Positive (1)	TP – Số trường hợp mà mô hình dự đoán đúng là mặt hàng sẽ hết hàng và thực tế mặt hàng đó hết hàng.	FN – Số trường hợp mà mô hình dự đoán không hết hàng nhưng thực tế mặt hàng đó lại hết hàng (có thể dẫn đến mất doanh thu).
	Negative (0)	FP – Số trường hợp mà mô hình dự đoán mặt hàng sẽ hết hàng nhưng thực tế mặt hàng đó không hết hàng (có thể dẫn đến chi phí không cần thiết cho giao hàng nhanh).	TN – Số trường hợp mà mô hình dự đoán đúng là mặt hàng sẽ không hết hàng và thực tế mặt hàng đó không hết hàng.

5. Chọn đáp án A

Giải thích: Giao hàng nhanh sẽ được thực hiện khi mô hình dự đoán xác suất cao hơn $p = 0.7$.

- Số trường hợp dự đoán hết hàng là: $TP + FP = 53 + 8$
→ Số tiền cần trả để giao hàng nhanh: $(53 + 8)D$.
- Chi phí của việc hết hàng liên quan đến các trường hợp dự đoán không hết hàng nhưng thực tế lại hết hàng là: $FN = 47$
→ Chi phí hết hàng: $47C$.
- KL: Vậy ta có tổng chi phí khi $p = 0.7$ là: $53D + 47C + 8D$.

6. Chọn đáp án A

Giải thích: Ta sẽ tính tổng chi phí với $C = 20D$

- Khi $p = 0.3$, ta có: $140D + 9C \rightarrow$ tổng chi phí = $320D$
- Khi $p = 0.5$, ta có: $103D + 24C \rightarrow$ tổng chi phí = $583D$
- Khi $p = 0.7$, ta có: $61D + 47C \rightarrow$ tổng chi phí = $1001D$

Với mục tiêu mở rộng thị phần và giảm thiểu tổn thất do hết hàng, ngưỡng $p = 0.3$ là lựa chọn tốt nhất. Nó giúp giảm thiểu chi phí tổng thể, từ đó hỗ trợ nhà bán lẻ tối ưu hóa nguồn lực và phát triển thị phần mà không gặp phải rủi ro lớn từ việc hết hàng.

Câu 7 – 10

7. Chọn đáp án A
8. Chọn đáp án B
9. Chọn đáp án C
10. Chọn đáp án D

Câu 11

11. Trong số các mô hình được đưa ra, em lựa chọn mô hình 5 vì mô hình này phù hợp nhất với tiêu chí mà đề bài đưa ra “Nếu không thể dự đoán xếp hạng của các trường học từ các yếu tố khác, nhưng vẫn có thể phân loại các trường mới mở một cách hợp lý (với mục tiêu là dự đoán sự tăng giá nhà)”. Cụ thể:
- Mô hình 1 điền dữ liệu thiếu bằng điểm trung bình xếp hạng từ phần còn lại của dữ liệu, điều này có thể không phản ánh chính xác xếp hạng của trường.
 - Mô hình 2 dự đoán xếp hạng trường dựa trên các yếu tố khác, tuy nhiên chúng có thể không chính xác, đặc biệt nếu các yếu tố này không liên quan chặt chẽ đến xếp hạng trường.
 - Mô hình 3 có nhược điểm là tính phức tạp do yêu cầu xây dựng và quản lý hai mô hình hồi quy riêng biệt, điều này không chỉ tăng rủi ro về chất lượng dự đoán mà còn đòi hỏi nhiều thời gian và tài nguyên để duy trì.
 - Mô hình 4 chỉ xác định được các trường bị thiếu thông tin mà không dự đoán được xếp hạng của trường và cũng không phân loại được các trường bị thiếu thông tin cụ thể vì lí do gì, nói cách khác mô hình này không cung cấp thông tin hữu ích để dự đoán giá nhà.
 - Mô hình 5 tuy không dự đoán xếp hạng cụ thể nhưng lại hiệu quả trong việc phân loại các trường mới mở một cách hợp lý.

Câu 12 – 13

12. Trong hình A, biến x_2 không quan trọng trong việc phân loại các điểm đen trắng. Vì khi x_2 trong khoảng $(0; 5)$, có rất nhiều điểm màu đen và màu trắng cùng nằm trong khoảng này. Trong khi đó đối với x_1 , xét x_1 trong nửa khoảng $[0; 4)$ thì có đa số là điểm màu đen và xét x_1 trong nửa khoảng $[4; 8)$ thì có đa số là điểm màu trắng.
13. Chọn đáp án A

Phần 2: Tự Luận

14. Có thể điều chỉnh phân tích như sau:

- Chia dữ liệu tội phạm thành 2 tập, sau đó thực hiện phân tích riêng từng tập:
 - + Tập dữ liệu ban ngày: Bao gồm các sự kiện tội phạm xảy ra trong khoảng thời gian ban ngày (ví dụ: từ 6 giờ sáng đến 6 giờ chiều).
 - + Tập dữ liệu ban đêm: Bao gồm các sự kiện tội phạm xảy ra vào ban đêm (ví dụ: từ 6 giờ chiều đến 6 giờ sáng).
- Với từng tập, chạy thuật toán k-means với các giá trị khác nhau. Sau đó vẽ biểu đồ và tìm điểm “khuỷu tay”, nơi mà thêm k không làm giảm đáng kể độ biến thiên.
- Lựa chọn k riêng biệt cho tập dữ liệu ban ngày và ban đêm. k cho dữ liệu ban ngày và k cho dữ liệu ban đêm có thể khác nhau, vì mỗi tập dữ liệu có thể có cấu trúc tội phạm khác nhau. Từ đó, tổ tuần tra ca ngày và ca đêm có thể tập trung quản lý những khu vực xảy ra nhiều sự kiện tội phạm ứng với từng khoảng thời gian.

15. Để phát hiện giá trị ngoại lai trong một bộ dữ liệu, có 3 cách đó là: xác định trực tiếp, sử dụng độ lệch chuẩn (Standard Deviation) và sử dụng phạm vi phân vị (IQR – Interquartile Range). Cụ thể:

- Xác định trực tiếp:
 - + Vẽ biểu đồ và nhìn trực tiếp
- Sử dụng độ lệch chuẩn:
 - + B1: Xác định giá trị trung bình (mean) và độ lệch chuẩn (standard deviation) của tập dữ liệu.
 - + B2: Xác định một ngưỡng (threshold) dựa trên số lần độ lệch chuẩn. (Thông thường, ngưỡng này là 3 độ lệch chuẩn.)
 - + B3: Xem xét tất cả các giá trị nằm ngoài khoảng từ $\text{mean} - 3 * \text{standard deviation}$ đến $\text{mean} + 3 * \text{standard deviation}$ là outliers.
- Sử dụng phạm vi phân vị:
 - + B1: Tính Q1 và Q3 của tập dữ liệu.
 - + B2: Tính $\text{IQR} = Q3 - Q1$.
 - + B3: Xác định hai ngưỡng dựa trên IQR.
 - Ngưỡng dưới là $Q1 - 1.5 * \text{IQR}$.
 - Ngưỡng trên là $Q3 + 1.5 * \text{IQR}$.
 - + B4: Tất cả các giá trị nằm ngoài khoảng từ ngưỡng dưới đến ngưỡng trên được xem là điểm ngoại lệ.

16. Để chọn k phù hợp trong phân cụm k -means, ta sử dụng phương pháp “khuỷu tay”. Cách hoạt động của phương pháp này như sau:

- Xây dựng mô hình k -means: Chạy thuật toán k -means với nhiều giá trị khác nhau của số cụm (k) và tính toán tổng độ sai lệch (inertia) cho mỗi giá trị k .
 - + Độ sai lệch (inertia) là một chỉ số đo lường mức độ phân tán của các điểm dữ liệu trong các cụm. Cụ thể, nó được tính bằng tổng khoảng cách bình phương từ mỗi điểm dữ liệu đến tâm của cụm mà nó thuộc về.
 - + Ý nghĩa của độ sai lệch:
 - Giá trị thấp: Nếu độ sai lệch thấp, điều này cho thấy rằng các điểm dữ liệu trong cùng một cụm gần nhau, tức là cụm đó có tính đồng nhất cao.
 - Giá trị cao: Nếu độ sai lệch cao, điều này cho thấy rằng các điểm trong cụm phân tán xa nhau, tức là cụm đó có tính đồng nhất thấp.
- Vẽ đồ thị: Vẽ đồ thị với số cụm (k) trên trục hoành và tổng độ sai lệch trên trục tung.
- Tìm "khuỷu tay": Quan sát đồ thị và tìm điểm mà độ sai lệch bắt đầu giảm với tốc độ chậm lại, tạo thành hình dạng giống như một khuỷu tay. Điểm này cho biết số cụm tối ưu, vì sau đó việc tăng số cụm sẽ không mang lại cải thiện đáng kể cho mô hình.
- ➔ Ý nghĩa: Phương pháp này giúp người dùng chọn số cụm hợp lý, tránh việc chọn quá nhiều hoặc quá ít, từ đó cải thiện hiệu suất của mô hình phân cụm.

17. Một ví dụ về bias-variance tradeoff là Overfitting (high variance), nghĩa là mô hình quá phức tạp và quá mức phù hợp với dữ liệu huấn luyện, trở nên quá nhạy cảm với nhiễu và ảnh hưởng ngẫu nhiên. Mức độ variance cao dẫn đến overfitting, hiển thị hiệu suất tốt trên tập huấn luyện nhưng kém trên tập kiểm thử. Giải pháp gồm có lọc biến và regularization.

18. Giả sử em có một mô hình đánh giá rủi ro khách hàng có trả được nợ không. Để kiểm tra xem mô hình có hoạt động hiệu quả hay không, em sẽ sử dụng số đo Precision. Lí do là vì:

		Actual values	
		Positive (1)	Negative (0)
Predicted values	Positive (1)	TP (<i>dự đoán khách hàng không trả được nợ và thực tế khách hàng không trả được nợ</i>)	FP (<i>dự đoán khách hàng không trả được nợ nhưng thực tế khách hàng trả được nợ</i>)
	Negative (0)	FN (<i>dự đoán khách hàng trả được nợ nhưng thực tế khách hàng không trả được nợ</i>)	TN (<i>dự đoán khách hàng trả được nợ và thực tế khách hàng trả được nợ</i>)

- Precision đo lường xem trong số các khách hàng dự đoán không trả được nợ (True Positive) thì mô hình dự đoán đúng bao nhiêu mẫu.
- Mô hình ưu tiên loại bỏ trường hợp dương tính giả (False Positive). Cụ thể: một khách hàng trả được nợ nhưng bị gán thành không trả được nợ. Nếu mô hình có precision cao thì có nghĩa là trong số những khách hàng mà mô hình dự đoán không trả được nợ, tỷ lệ những khách hàng thực sự không trả được nợ là lớn. Điều này quan trọng vì nếu mô hình gán nhầm nhiều khách hàng trả nợ thành không trả nợ (dương tính giả), ta sẽ mất cơ hội cho vay và thu hồi nợ từ những khách hàng tiềm năng.

19. Xây dựng một mô hình dự đoán gian lận thẻ tín dụng.

- Dữ liệu gồm có:
 - + Các biến đặc trưng:
 - Số tiền giao dịch
 - Thời gian giữa các giao dịch
 - Các biến số được biến đổi khác (vì lí do bảo mật)
 - + Biến mục tiêu:
 - Có gian lận không?
 - Có (1): Gian lận
 - Không (0): Không gian lận
- Mô hình sử dụng: Cây quyết định
- Kết quả nhận được:
 - + Mô hình cây quyết định dự đoán giao dịch thẻ tín dụng là gian lận hay không gian lận.
 - + Ngưỡng sử dụng:
 - Ngưỡng phân loại được thiết lập là 0.5.
 - Nếu xác suất dự đoán lớn hơn hoặc bằng 0.5, giao dịch sẽ được phân loại là "Gian lận" (1).
 - Nếu xác suất dự đoán nhỏ hơn 0.5, giao dịch sẽ được phân loại là "Không gian lận" (0).
 - Tùy chỉnh ngưỡng: Dựa vào phân tích chi phí - lợi ích, có thể điều chỉnh ngưỡng lên hoặc xuống.
 - Ngưỡng nhỏ hơn 0.5: Nếu ngân hàng muốn phát hiện nhiều giao dịch gian lận hơn, có thể chọn ngưỡng thấp hơn (ví dụ: 0.4) để tăng khả năng phát hiện gian lận, nhưng sẽ làm tăng số lượng giao dịch hợp lệ bị từ chối.
 - Ngưỡng lớn hơn 0.5: Nếu ngân hàng muốn giảm số lượng giao dịch hợp lệ bị từ chối, có thể chọn ngưỡng cao hơn (ví dụ: 0.6), từ đó giảm số lượng dự đoán gian lận nhưng có nguy cơ bỏ lỡ một số giao dịch gian lận.
 - + Các thông số đánh giá hiệu suất của mô hình:
 - Accuracy: Tỷ lệ các dự đoán đúng trên tổng số dự đoán.
 - Precision: Tỷ lệ các dự đoán đúng là gian lận trên tổng số dự đoán là gian lận.
 - Recall: Tỷ lệ các dự đoán đúng là gian lận trên tổng số thực tế là gian lận.

20. Xây dựng một mô hình phân loại một hộ gia đình sẽ vượt quá thời hạn thanh toán hoặc gặp khó khăn trong việc thanh toán hóa đơn điện.

- Dữ liệu gồm có:
 - + Các biến đặc trưng:
 - o Hóa đơn thanh toán
 - o Mức độ nợ nần
 - o Đặc điểm của hộ gia đình
 - o Mức tiêu thụ điện hàng tháng
 - o Các biến số khác ảnh hưởng đến việc cung cấp điện
 - + Biến mục tiêu:
 - o Hộ gia đình sẽ vượt quá thời hạn thanh toán hoặc gặp khó khăn trong việc thanh toán hóa đơn điện?
 - Có (1): Gặp khó khăn
 - Không (0): Không gặp khó khăn
- Mô hình sử dụng: Hồi quy logistic
- Kết quả nhận được:
 - + Mô hình hồi quy logistic dự đoán xác suất một hộ gia đình sẽ gặp khó khăn trong việc thanh toán hóa đơn điện.
 - + Ngưỡng sử dụng:
 - o Ngưỡng phân loại được thiết lập là 0.5.
 - Nếu xác suất dự đoán lớn hơn hoặc bằng 0.5, hộ gia đình sẽ được phân loại là "Gặp khó khăn" (1).
 - Nếu xác suất dự đoán nhỏ hơn 0.5, hộ gia đình sẽ được phân loại là "Không gặp khó khăn" (0).
 - o Tùy chỉnh ngưỡng: Dựa vào phân tích chi phí - lợi ích, có thể điều chỉnh ngưỡng lên hoặc xuống.
 - Ngưỡng nhỏ hơn 0.5: Nếu công ty muốn đảm bảo rằng nhiều khách hàng gặp khó khăn hơn được phát hiện, có thể chọn ngưỡng thấp hơn (ví dụ: 0.4), từ đó tăng khả năng cắt điện cho những khách hàng thực sự gặp khó khăn.
 - Ngưỡng lớn hơn 0.5: Nếu công ty muốn cẩn trọng hơn trong việc xác định khách hàng gặp khó khăn, có thể chọn ngưỡng cao hơn (ví dụ: 0.6) để giảm thiểu việc cắt điện cho những khách hàng không gặp khó khăn.
 - + Các thông số đánh giá hiệu suất của mô hình:
 - o Accuracy: Tỷ lệ các dự đoán đúng trên tổng số dự đoán.
 - o Precision: Tỷ lệ các dự đoán đúng là gặp khó khăn trên tổng số dự đoán là gặp khó khăn.
 - o Recall: Tỷ lệ các dự đoán đúng là gặp khó khăn trên tổng số thực tế là gặp khó khăn.

Bonus

1. Đúng. Trong bài toán phân loại, chúng ta cung cấp cho máy tính cả dữ liệu đầu vào và đầu ra mong muốn (nhãn). Nói cách khác, máy tính được đào tạo trên một tập dữ liệu đã được gán nhãn.
2. Sai. Dự đoán mức lương tương lai dựa trên điểm số tại GTSI không phải là ví dụ về phân loại mà là ví dụ hồi quy do kết quả đầu ra mức lương tương lai là một giá trị liên tục và mang tính chất dự đoán.