

Bài Thi Cuối Kỳ

Phần 1: Trắc Nghiệm & Trả Lời Câu Hỏi Ngắn

Câu 1 (5 điểm)

1. Chọn đáp án đúng nhất trong 4 lựa chọn sau về việc phân tách dữ liệu trong xây dựng mô hình.
 - a. 70% cho huấn luyện, 15% cho kiểm tra, 15% cho kiểm tra lại
 - b. 15% cho huấn luyện, 70% cho kiểm tra, 15% cho kiểm tra lại
 - c. 15% cho huấn luyện, 15% cho kiểm tra, 70% cho kiểm tra lại
 - d. 55% cho huấn luyện, 15% cho kiểm tra chéo, 15% cho kiểm tra, 15% cho kiểm tra lại

Câu 2 - 4 (15 điểm)

Một nhà địa chất muốn xây dựng một mô hình để dự đoán xác suất núi lửa phun trào trong một tuần nhất định. Nhà địa chất có dữ liệu núi lửa phun trào trước đó, cũng như một số yếu tố có thể được sử dụng làm biến dự đoán.

2. Trong các mô hình sau, mô hình nào sẽ **phù hợp nhất** cho nhà địa chất để dự đoán xác suất núi lửa phun trào? (5 điểm)
 - a. K-means
 - b. Linear Regression
 - c. Cross Validation
 - d. Logistic Regression
3. Chọn những mô hình mà nhà địa chất có thể sử dụng để phân loại điểm dữ liệu thành "phun trào" hoặc "không phun trào". **Có thể chọn nhiều hơn 1 đáp án.** (5 điểm)
 - a. Linear Regression
 - b. Decision Tree
 - c. K-means
 - d. K-nearest-neighbor
 - e. Random Forest
 - f. Cross Validation
4. Nhà địa chất đã sử dụng một ngưỡng đơn giản là 50%: nếu mô hình dự đoán có xác suất 50% trở lên rằng núi lửa sẽ phun trào, nhà địa chất đề xuất rằng các thị trấn lân cận nên sơ tán. Theo bạn, 50% có phải ngưỡng hợp lý không? hay nó nên cao hơn, hoặc thấp hơn? **Giải thích vì sao.**

Câu 5 - 6 (10 điểm)

Một mô hình hồi quy logistic đã được phát triển để đoán trước khả năng một mặt hàng ưa dùng sẽ hết hàng trước khi nhập thêm từ nhà sản xuất. Mô hình này xem xét các yếu tố như lượng hàng tồn kho hiện tại, nhu cầu trong quá khứ, và các chương trình khuyến mãi, để đưa ra dự đoán.

Nếu dự đoán từ mô hình này vượt qua một ngưỡng giá trị p , cửa hàng sẽ cần trả thêm tiền để giao hàng nhanh hơn và tránh tình trạng hết hàng.

Dưới đây là ba bảng kết quả dự đoán, mỗi bảng tương ứng với một ngưỡng p khác nhau.

Confusion Matrix 1:

$p=0.3$	Dự đoán hết hàng	Dự đoán không hết hàng
Thực tế hết hàng	91	9
Thực tế không hết hàng	49	51

Confusion Matrix 2:

$p=0.5$	Dự đoán hết hàng	Dự đoán không hết hàng
Thực tế hết hàng	76	24
Thực tế không hết hàng	27	73

Confusion Matrix 3:

$p=0.7$	Dự đoán hết hàng	Dự đoán không hết hàng
Thực tế hết hàng	53	47
Thực tế không hết hàng	8	92

5. Giả sử D là số tiền cần trả để giao hàng nhanh (nếu mô hình dự đoán cao hơn p). C là chi phí của việc hết hàng. Chọn các câu đúng dưới đây. **Có thể chọn nhiều hơn 1 đáp án.** (5 điểm)
- Khi $p = 0.7$, tổng chi phí là $53D + 47C + 8D$.
 - Khi $p = 0.7$, tổng chi phí là $53D + 47D + 8C$.
 - Tổng chi phí khi $p = 0.7$ phải lớn hơn so với khi $p = 0.5$ và $p = 0.3$.
6. Mục tiêu chính của nhà bán lẻ lúc này là mở rộng thị phần của mình. Họ ước tính rằng việc hết hàng sẽ gây tổn thất nhiều hơn 20 lần so với việc trả tiền để giao hàng sớm (tức là $C = 20D$). Bạn sẽ đề xuất ngưỡng p nào? **Có thể chọn nhiều hơn 1 đáp án.** (5 điểm)
- $p = 0.3$
 - $p = 0.5$
 - $p = 0.7$


Câu 7 - 10 (20 điểm)



Dưới đây là các hình minh họa cho các tập dữ liệu sẽ được sử dụng trong thuật toán phân cụm k-means. Trong thuật toán này, khoảng cách giữa các giá trị rất quan trọng.


Mỗi tập dữ liệu đều có hai thuộc tính.

Hình 1: Gồm 2 thuộc tính




- Thuộc tính 1: các điểm dữ liệu có giá trị từ 0 tới 10
- Thuộc tính 2: các điểm dữ liệu có giá trị từ 0 tới 10, và có một điểm có giá trị bằng 1000

Hình 2: Gồm 2 thuộc tính




- Thuộc tính 1: các điểm dữ liệu có giá trị từ 0 tới 10
- Thuộc tính 2: các điểm dữ liệu có giá trị từ 0 tới 10

Hình 3: Gồm 2 thuộc tính



- Thuộc tính 1: các điểm dữ liệu có giá trị từ 0 tới 10
- Thuộc tính 2: các điểm dữ liệu có giá trị từ 0 tới 1000

Hình 4: Gồm 2 thuộc tính



- Thuộc tính 1: các điểm dữ liệu có giá trị từ 0 tới 1000
- Thuộc tính 2: các điểm dữ liệu có giá trị từ 0 tới 10, và có một điểm có giá trị bằng 1000



Câu hỏi: Bạn cần thực hiện những gì để chuẩn bị dữ liệu sao cho phương pháp k-means hoạt động tốt trên mỗi tập dữ liệu?

Chọn **đáp án đúng nhất** cho mỗi hình.

7. Hình 1 (5 điểm)

- a. Chỉ loại bỏ dữ liệu ngoại lai
- b. Không loại bỏ dữ liệu ngoại lai và không chuẩn hoá dữ liệu
- c. Chỉ chuẩn hoá dữ liệu
- d. Đầu tiên bỏ dữ liệu ngoại lai, sau đó chuẩn hoá dữ liệu

8. Hình 2 (5 điểm)

- a. Chỉ loại bỏ dữ liệu ngoại lai
- b. Không loại bỏ dữ liệu ngoại lai và không chuẩn hoá dữ liệu
- c. Chỉ chuẩn hoá dữ liệu
- d. Đầu tiên bỏ dữ liệu ngoại lai, sau đó chuẩn hoá dữ liệu

9. Hình 3 (5 điểm)

- a. Chỉ loại bỏ dữ liệu ngoại lai
- b. Không loại bỏ dữ liệu ngoại lai và không chuẩn hoá dữ liệu
- c. Chỉ chuẩn hoá dữ liệu
- d. Đầu tiên bỏ dữ liệu ngoại lai, sau đó chuẩn hoá dữ liệu

10. Hình 4 (5 điểm)

- a. Chỉ loại bỏ dữ liệu ngoại lai
- b. Không loại bỏ dữ liệu ngoại lai và không chuẩn hoá dữ liệu
- c. Chỉ chuẩn hoá dữ liệu
- d. Đầu tiên bỏ dữ liệu ngoại lai, sau đó chuẩn hoá dữ liệu

Câu 11 (5 điểm)

11. Có 5 mô hình phân loại được dùng để dự đoán biến động lớn về giá nhà, dựa vào dữ liệu đầu vào bao gồm xếp hạng của các trường tiểu học công lập tại khu vực tương ứng và một số yếu tố khác.

Tuy nhiên, trong tập huấn luyện, xếp hạng của các trường tiểu học mới mở (chiếm 3% tập dữ liệu) bị thiếu. Các trường mới xây dựng thì không có xếp hạng, nên những khu vực có dân số tăng nhanh gần đây có khả năng thiếu dữ liệu xếp hạng trường cao hơn.

Nếu không thể dự đoán được xếp hạng của các trường học từ các yếu tố khác, nhưng vẫn có thể phân loại các trường mới mở một cách hợp lý (với mục tiêu là dự đoán sự tăng giá nhà), bạn sẽ sử dụng mô hình nào trong số những mô hình sau đây? **Giải thích vì sao.**

- (a) Mô hình 1: Điền dữ liệu thiếu bằng điểm trung bình xếp hạng từ phần còn lại của dữ liệu.
- (b) Mô hình 2: Xây dựng một mô hình hồi quy để điền vào dữ liệu thiếu dựa trên các biến khác.
- (c) Mô hình 3: Đầu tiên, dùng mô hình phân loại để đoán xem một trường mới có phải được xây dựng do tăng trưởng dân số hay vì lý do khác. Sau đó, xây dựng 2 mô hình hồi quy để dự đoán xếp hạng trường: một cho các khu vực với trường mới được xây dựng do tăng trưởng

dân số và một cho các khu vực với trường mới được xây dựng vì lý do khác.

(d) Mô hình 4: Sử dụng biến nhị phân để xác định các địa điểm có thông tin bị thiếu.

(e) Mô hình 5: Sử dụng biến phân loại. Đầu tiên, dùng mô hình phân loại để dự đoán xem một trường mới có phải được xây dựng do tăng trưởng dân số hay không. Sau đó, mỗi khu vực được phân loại là "có dữ liệu", "thiếu thông tin, do tăng trưởng dân số" hoặc "thiếu thông tin, do lý do khác".

Câu 12 - 13 (10 điểm)

Hình A (Figure A) phân loại các điểm dữ liệu thành hai nhóm, nhóm điểm màu đen và nhóm điểm màu trắng. Hai nhóm này được phân loại bởi đường kẻ đứt (dashed line) màu đỏ. Hình B (Figure B) biểu diễn một cây quyết định (decision tree) để giải quyết cùng một vấn đề.






Figure B

In each leaf, "a out of b" means that there are b data points in the leaf, and a of them are classified correctly using the leaf's answer.


12. Trong hình A, biến nào không quan trọng trong việc phân loại các điểm đen và trắng? x_1 hay x_2 ? **Giải thích vì sao.** (5 điểm)
13. Trong hình B, cả hai biến x_1 và x_2 đều được sử dụng để phân loại các điểm (mặc dù ở hình A, một biến được xem là không quan trọng). Giữa mô hình ở hình A và mô hình ở hình B, mô hình nào phân loại tốt hơn? (5 điểm)
- Mô hình ở hình A, vì mô hình ở hình B bị overfit, đặc biệt ở nút lá góc bên phải
 - Mô hình ở hình B, vì decision tree phức tạp hơn
 - Mô hình ở hình B, vì nó sử dụng cả 2 biến để dự đoán
 - Mô hình ở hình A, vì nó đơn giản hơn

Phần 2: Tự Luận


14. Một nhóm cảnh sát đã sử dụng thuật toán k-means để phân loại các khu vực có mức độ tội phạm cao trong thành phố. Họ đề xuất đặt các đội cảnh sát tại những nơi này để giảm tội phạm. Ba biểu đồ dưới đây minh họa kết quả cho ba trường hợp khác nhau: khi $k=2$, $k=3$ và $k=4$. Các hình tròn đại diện cho các vùng tội phạm, trong khi các ngôi sao là trung tâm của các vùng tội phạm này.



$k=2$



$k=3$



$k=4$

Ban đầu, họ chọn kết quả khi $k=4$, dựa trên phạm vi tuần tra hiệu quả của các đội cảnh sát. Tuy nhiên, sau đó họ nhận ra một số tội phạm xảy ra vào ban ngày và một số vào ban đêm, nên họ cần hai tổ tuần tra mới, cho cả ngày và cả đêm. Bạn nghĩ họ nên điều chỉnh phân tích trên như thế nào để phù hợp với tình hình mới này? (5 điểm)

15. Làm thế nào để phát hiện giá trị ngoại lai trong một bộ dữ liệu? (5 điểm)
16. Làm thế nào để chọn k phù hợp trong phân cụm k -means? (5 điểm)
17. Mô tả một ví dụ cụ thể về bias-variance tradeoff (5 điểm)
18. Giả sử bạn có một mô hình đánh giá rủi ro khách hàng có trả được nợ không. Làm thế nào để kiểm tra xem mô hình có hoạt động hiệu quả hay không? (5 điểm)
19. Giả sử bạn cần xây dựng một mô hình dự đoán gian lận thẻ tín dụng. Mô tả dữ liệu và mô hình bạn có thể sử dụng. Gợi ý: Trả lời câu hỏi dưới định dạng sau: Cho {dữ liệu}, sử dụng {mô hình} để {kết quả}. (5 điểm)
20. Công ty điện XYZ đang đối diện với thách thức về việc xác định những hộ dân nên hoặc không nên bị cắt điện trong các tình huống cụ thể. Trong bối cảnh này, việc phát triển một mô hình phân loại hiệu quả có thể giúp công ty này đưa ra quyết định hợp lý và minh bạch.

Nhiệm vụ của bạn là xây dựng một mô hình phân loại dựa trên dữ liệu lịch sử và các yếu tố khác nhau như hóa đơn thanh toán, mức độ nợ nần, đặc điểm của hộ gia đình, và các biến số khác có thể ảnh hưởng đến việc cung cấp điện. Mô hình này cần có khả năng dự đoán xác suất một hộ gia đình sẽ vượt quá thời hạn thanh toán hoặc gặp khó khăn trong việc thanh toán

hóa đơn điện.

Mô tả dữ liệu và mô hình bạn có thể sử dụng. Gợi ý: Trả lời câu hỏi dưới định dạng sau: Cho {dữ liệu}, sử dụng {mô hình} để {kết quả}.

(5 điểm)

Bonus (5 điểm)

1. [Trả lời: Đúng hoặc Sai; Giải thích ngắn gọn] Phân loại là nhiệm vụ gán các đối tượng vào một trong vài danh mục đã xác định trước. (2 điểm)
2. [Đúng hoặc Sai; Giải thích ngắn gọn] Ví dụ về phân loại bao gồm việc phát hiện các thư rác dựa trên tiêu đề và nội dung thư, phân loại tế bào là ác tính hoặc lành tính dựa trên kết quả của quét MRI, dự đoán mức lương tương lai dựa trên điểm số tại GTSI và phân loại các thiên hà dựa trên hình dạng của chúng. (2 điểm)
3. Nêu cảm nhận của em về lớp Khai Phá Dữ Liệu. Điểm nào em thấy lớp đã làm tốt và điểm nào em thấy cần cải thiện. (1 điểm)